

Spektrogramm und Sprachaktivität: Frequenzen über der Zeit

Labor Versuch TP4

Digitale Audiosignalverarbeitung

Begleitheft zum Jupyter-Notebook TP4_Spektrogramm_Sprachaktivitaet.ipynb

Name, Vorname	Matrikelnummer	Gruppe

1 Hinweise zur Durchführung

Gerechnet, gezeichnet und angehört wird im zugehörigen Jupyter-Notebook (Dateiname auf der Titelseite). Dieses Heft führt durch den Versuch. Abschnitte und Aufgaben haben im Heft und im Notebook **dieselben Nummern**. Das Notebook braucht kein anderes Notebook.



Notebook in Google Colab öffnen:

https://colab.research.google.com/github/Lamhour-Mohamed-Akram/audio-dsp-lab/blob/main/TP4_Spektrogramm_Sprachaktivitaet.ipynb

- **Öffnen:** Link oder QR-Code öffnen, gegebenenfalls mit einem Google-Konto anmelden und die Zellen von oben nach unten mit **Shift + Enter** ausführen. Eine Warnung, dass das Notebook nicht von Google stammt, mit „Trotzdem ausführen“ bestätigen.
- **Antworten:** in dieses Heft **oder** in eine eigene Kopie des Notebooks (*Datei > Kopie in Drive speichern*). Schreibrechte für das Original sind nicht nötig.
- **Pflicht und Zusatz:** Pflichtaufgaben bearbeiten alle, Zusatzaufgaben sind freiwillig.
Zeitbedarf (Schätzung): Pflichtaufgaben 4.1 bis 4.4 ca. 60 bis 90 Minuten nach der Einrichtung.
- **Arbeitsweise:** immer nur ein oder zwei Parameter ändern, Zelle erneut ausführen, hören, beobachten und notieren. Kopfhörer verwenden.

1.1 Einrichtung

Die ersten zwei Code-Zellen installieren nur fehlende Python-Pakete und laden **speech.wav**, **music.wav** und **sound.wav** automatisch in den Ordner **data/**, falls sie fehlen oder beschädigt sind. Uploads, Google Drive, ein GitHub-Konto oder eine GPU sind nicht nötig. **Neustart:** Nach *Sitzung neu starten* sind die Variablen weg, die Dateien bleiben. Nach *Laufzeit trennen und löschen* oder in einer neuen Laufzeit sind auch die Dateien weg. Dann Abschnitt 1 und alle Zellen bis zur aktuellen Stelle erneut ausführen, am einfachsten mit *Laufzeit > Alle ausführen*.

1.2 Bibliotheken und Hilfsfunktionen

Eine Zelle lädt die Bibliotheken und die aus TP2 bekannten Hilfsfunktionen, zum Beispiel **an hoeren** (ohne automatische Lautstärke-Anpassung), **gemeinsame_skala** und **spektrum**.

2 Lernziele

Nach diesem Versuch können Sie

- den Unterschied zwischen dem Spektrum der ganzen Aufnahme und einem Spektrogramm erklären,
- Spektrogramme von Sprache, Musik und Geräusch lesen und vergleichen,

- ein Mel-Spektrogramm in einfachen Worten erklären,
- mit der Kurzzeit-Energie ungefähr erkennen, wann gesprochen wird,
- zeigen, wann diese Methode versagt (Rauschen, leise Sprache),
- Sprachaktivitätserkennung, Sprechererkennung und Spracherkennung unterscheiden.

3 Vorbereitungsaufgaben

Bearbeiten Sie diese Aufgaben **vor** dem Labor. Kurze Antworten genügen.

V1: Ein Spektrogramm benutzt Fenster von 32 ms. Wie viele Samples sind das bei 16000 Hz?

V2: Das Spektrum der ganzen Aufnahme zeigt nicht, wann eine Frequenz vorkommt. Warum ist das bei Sprache ein Nachteil?

V3: Menschen hören den Unterschied zwischen 100 Hz und 200 Hz sehr deutlich, zwischen 8000 Hz und 8100 Hz kaum. Was bedeutet das für eine gehörgerechte Frequenzachse?

V4: Erklären Sie den Unterschied zwischen den Fragen: Wann spricht jemand? Wer spricht? Was wird gesagt?

4 Durchführung

4.1 Vom Spektrum zum Spektrogramm (Aufgabe 4.1, Pflicht)

Ziel: Sehen, wie sich der Frequenzinhalt über der Zeit ändert.

Die FFT der ganzen Aufnahme mischt alle Zeitpunkte zusammen. Ein **Spektrogramm** zerlegt das Signal in kurze, überlappende Fenster, berechnet für jedes Fenster eine FFT und zeigt die Spektren nebeneinander: x-Achse Zeit, y-Achse Frequenz, Farbe Stärke (hell = stark, 0 dB =

stärkster Punkt des Bildes). Parameter: `n_fft` ist die Fensterlänge in Samples (gültig 64 bis 8192), `hop` der Schritt von Fenster zu Fenster (gültig 1 bis `n_fft`). Voreinstellung: `n_fft` = 512 (32 ms bei 16000 Hz) und `hop` = 128.

Aufgabe 4.1 (Pflicht)

- Finden Sie im Spektrogramm die Pausen (dunkle senkrechte Streifen). Nennen Sie zwei Zeitpunkte.
 - In Vokalen sieht man viele waagerechte Linien übereinander. Was stellen sie dar?
 - Setzen Sie `n_fft` = 128 und danach `n_fft` = 2048. Was wird jeweils schärfer: die zeitliche Darstellung oder die Frequenzdarstellung?
-
-

4.2 Sprache, Musik, Geräusch und Mel-Spektrogramm (Aufgabe 4.2, Pflicht)

Ziel: Typische Muster erkennen und die Mel-Skala kennenlernen.

- Das Notebook zeigt die Spektrogramme aller drei Aufnahmen untereinander. Stereo wird nur für die Darstellung zu Mono gemittelt.
- Das Gehör unterscheidet tiefe Frequenzen fein und hohe grob. Die **Mel-Skala** bildet das nach. Ein **Mel-Spektrogramm** fasst die FFT-Frequenzen zu wenigen Mel-Bändern zusammen. Solche Bilder werden häufig als Eingabe für KI-Modelle benutzt, zum Beispiel für neuronale Netze, die Audio wie ein Bild verarbeiten.
- Parameter: `n_mels`, die Anzahl der Mel-Bänder (gültig 8 bis 128, Voreinstellung 64).

Aufgabe 4.2 (Pflicht)

- Beschreiben Sie in **Tabelle A** das typische Muster jeder Aufnahme. Achten Sie auf Pausen, lange waagerechte Linien (gehaltene Töne), senkrechte Striche (Schläge, Knacken), steigende oder fallende Linien (Tonhöhe ändert sich) und breites Rauschen.
 - Setzen Sie `n_mels` = 20 und danach `n_mels` = 128. Wie verändert sich das Mel-Spektrogramm? Sind Pausen und Vokale noch zu erkennen?
-
-

4.3 Sprachaktivität mit der Kurzzeit-Energie (Aufgabe 4.3, Pflicht)

Ziel: Ungefähr erkennen, wann in `speech.wav` gesprochen wird (Voice Activity Detection, VAD).

1. Das Signal wird in überlappende Fenster zerlegt (25 ms lang, Schritt 10 ms). Das letzte Fenster endet genau am Ende der Aufnahme.
2. Für jedes Fenster wird die Energie berechnet: der Mittelwert der quadrierten Samples.
3. Die Energie wird in dB umgerechnet, 0 dB ist das lauteste Fenster. Fenster ohne jede Energie erhalten minus unendlich dB.
4. Fenster über der Schwelle `schwelle_db` gelten als aktiv (gültig -100 bis 0 dB).
5. Aktive Fenster, die sich überlappen oder berühren, bilden einen Abschnitt vom Anfang des ersten bis zum Ende des letzten aktiven Fensters.

Die Grenzen sind **ungefähr** und entsprechen nicht genau den Wortgrenzen. Findet die Methode nichts, meldet das Notebook das, statt abzubrechen.

Aufgabe 4.3 (Pflicht)

Probieren Sie `schwelle_db` = -10, -20, -30, -40 und -50. Tragen Sie in **Tabelle B** die Anzahl der Abschnitte, den Anteil aktiver Fenster und Ihre Beobachtung ein: Fehlen Teile von Wörtern? Werden Pausen als aktiv markiert? Hören Sie dazu auch die aneinandergehängten aktiven Abschnitte an.

4.4 Grenzen der Methode (Aufgabe 4.4, Pflicht)

Ziel: Zeigen, wann eine Energie-Schwelle versagt.

- **a) Rauschen:** Das Notebook erzeugt die verrauschte Sprache selbst (`seed=42`, `vad_snr_db` = 10, Vorschläge 20, 10, 0) und wendet `schwelle_rauschen_db` = -30 an.
- **b) Leise Sprache:** Die zweite Hälfte wird mit `leise_faktor` = 0.03 (etwa -30 dB, gültig 0 bis 1) leiser gemacht. Die Schwelle `schwelle_leise_db` = -30 bezieht sich auf das lauteste Fenster der ganzen Aufnahme.

Aufgabe 4.4 (Pflicht)

- a) Beobachten Sie bei `vad_snr_db` = 10 und `schwelle_rauschen_db` = -30, welche Bereiche als aktiv markiert werden. Suchen Sie eine Schwelle, bei der die Pausen wieder als inaktiv erkannt werden (**Tabelle C**).
 - b) Welche Teile der leisen zweiten Hälfte werden bei `schwelle_leise_db` = -30 erkannt? Suchen Sie eine Schwelle, bei der die leise Sprache erkannt wird.
 - c) Gibt es eine gemeinsame Schwelle, die für beide Aufnahmen gut funktioniert? Was folgt daraus für diese einfache Methode?
-
-

4.5 Wann, wer, was? Drei verschiedene Aufgaben

Aufgabe	Frage	Beispiel für ein Ergebnis	In diesem Labor
Sprachaktivitäts-erkennung (VAD)	Wann wird gesprochen?	„aktiv von 0,4 s bis 2,1 s“	ja, einfach, mit der Kurzzeit-Energie
Sprechererkennung (speaker identification)	Wer spricht?	„Person A“	nein
Spracherkennung (ASR)	Was wird gesagt?	der gesprochene Text	nein

Eine Energie-Schwelle unterscheidet nur zwischen viel und wenig Energie: Laute Geräusche können als Sprache gelten, leise Sprache kann übersehen werden. Sie sagt nichts darüber, wer spricht oder was gesagt wird. `speech.wav` enthält eine einzige Sprecherstimme, damit kann man Sprechererkennung weder üben noch testen. Beide brauchen trainierte Modelle, in diesem Labor wird kein Modell trainiert.

4.6 Zusatzaufgabe Z4.1: Echo (optional)

Ein Echo ist eine verzögerte, leisere Kopie: Ausgang = Original + `daempfung` mal (Original, um `verzoegerung_ms` später). Gültig: `verzoegerung_ms` 1 bis 2000, `daempfung` 0 bis 1. Vergleichen Sie `verzoegerung_ms` = 50, 300 und 1000 sowie `daempfung` = 0.3 und 0.8. Wann hören Sie ein deutliches Echo? Wann klingt es eher wie ein Raum oder eine Klangfärbung?

4.7 Zusatzaufgabe Z4.2: MFCC (optional)

MFCCs fassen jedes Fenster des Mel-Spektrogramms in wenigen Zahlen zusammen (`n_mfcc` = 13, gültig 2 bis 40) und beschreiben grob die Klangfarbe. Sie sind klassische Eingaben für Verfahren des Maschinellen Lernens. Vergleichen Sie das MFCC-Bild mit dem Mel-Spektrogramm aus 4.2. Wo erkennen Sie die Pausen?

5 Auswertung und Diskussion

Tabelle A: Muster im Spektrogramm (Aufgabe 4.2 a)

Aufnahme	Typisches Muster
Sprache	
Musik	
Rennwagen	

Tabelle B: Schwelle der Sprachaktivitätserkennung für speech.wav (Aufgabe 4.3)

schwelle__db	Anzahl Abschnitte	Anteil aktiver Fenster [%]	Beobachtung (Wortteile fehlen? Pausen aktiv?)
-10			
-20			
-30			
-40			
-50			

Tabelle C: Grenzen der Methode (Aufgabe 4.4)

Aufnahme	Einstellung	geeignete Schwelle [dB]	Beobachtung
verrauschte Sprache	vad_snr_db = 10		
zweite Hälfte leise	leise_faktor = 0.03		

Fragen

1. Was zeigt ein Spektrogramm, was das FFT-Spektrum der ganzen Aufnahme nicht zeigt?

2. Was haben Sie bei `n_fft = 128` und `n_fft = 2048` beobachtet? Erklären Sie Ihre Beobachtung mit Zeit und Frequenz.

3. Warum passt die Mel-Skala besser zum menschlichen Hören als eine lineare Frequenzachse?

4. Welche Schwelle fanden Sie für `speech.wav` am geeignetsten? Wie hat sich dieselbe Schwelle bei der verrauschten und bei der leisen Aufnahme verhalten?

5. Warum kann eine Energie-Schwelle nicht erkennen, wer spricht oder was gesagt wird?

6. Nennen Sie eine Anwendung, in der Sprachaktivitätserkennung nützlich ist.

6 Quellen und Audiodaten

Die Aufnahmen stammen von Dritten. Für dieses Labor wurden nur Ausschnitte herausgeschnitten und als WAV-Dateien gespeichert (20 ms Ein- und Ausblenden an den Schnittstellen, sonst keine Bearbeitung). Alle Details stehen in `DATA_SOURCES.md` im Repository <https://github.com/Lamhour-Mohamed-Akram/audio-dsp-lab>. Die Übersicht aller Versuche mit Links steht dort in der Datei `README.md`.

- **speech.wav** (16000 Hz, mono, 15,9 s): LibriVox-Hörbuch „Fabeln“ von Magnus Gottfried Lichtwer, Abschnitt „Das Wiesel und die Hühner“, gelesen von marham63. Lizenz: Public Domain. Quelle: https://archive.org/details/fabeln_1905_librivox. Ausschnitt 12,8 s bis 28,7 s, umgetastet auf 16000 Hz.
- **music.wav** (44100 Hz, stereo, 20,0 s): Julius Fučík, „Entrance of the Gladiators“, gespielt von der United States Marine Band. Lizenz: Public Domain (Werk der US-Regierung). Quelle: Wikimedia Commons, Datei *Julius Fučík's Entrance of the Gladiators, performed by the United States Marine Band.flac* (<https://commons.wikimedia.org>). Ausschnitt 24 s bis 44 s.
- **sound.wav** (22050 Hz, stereo, 8,0 s): „Audi R8 (2000)“, aufgenommen von Edvvc beim Goodwood Festival of Speed 2009. Lizenz: CC BY-SA 3.0, <https://creativecommons.org/licenses/by-sa/3.0/>. Quelle: [https://commons.wikimedia.org/wiki/File:Audi_R8_\(2000\).ogg](https://commons.wikimedia.org/wiki/File:Audi_R8_(2000).ogg). Ausschnitt 4 s bis 12 s, umgetastet auf 22050 Hz. Der Ausschnitt steht ebenfalls unter CC BY-SA 3.0.